先看这一页

这份手册交给验收负责人、岗位专家、两位独立评分者和测试人员使用。它说明怎么操作、交什么记录、怎样判断资料够不够。正式工作样本已经存在，本次在其上增加验收流程，不重做 CV、30 题问卷或两个小游戏。

当前能说什么

项目	本版口径
流程与公式	有在线表单、Firebase 数据结构、权限规则和自动检查。上线及云端实测状态以仓库 release.json 的本轮记录为准。
专业岗位相关性	仍待相关领域专家审题；系统不能代替专家资历核对。
真实人工评分一致性	仍待真实参与者和两名独立人工评分者的数据。合成测试不计入。
A/B 等值、常模、预测效度	尚未建立；不能用不同变式成绩直接排名，也不能声称预测录用。

最短执行顺序

① 负责人从一个正式任务建立验收轮次，先写抽样与验收标准。
② 冻结版本，邀请专家审题，记录人工资历核对。
③ 选匿名作答，经本人分别授权给两名评分者，并另同意纳入本轮统计。
④ 两人独立提交分数及证据，负责人查看统计和排除原因。
⑤ 保存快照，记录分歧、修改或继续收集的决定，不能自动盖“通过”。

本轮可以验收“系统是否按约定运行”，但不能仅凭软件测试验收“专业效度已经成立”。

谁负责什么，谁不能看什么

角色	要做的事	访问边界
验收负责人	预先登记方案，分配材料，核对资历，查看汇总，追加处理意见。	仅本轮负责人读取本轮专家意见、研究名单和统计快照。
岗位专家	核对任务与岗位的关系，逐维度审题，指出遗漏和不公平要求。	只看分配给自己的题目、标准和冻结 job description；不看 CV、问卷、游戏或候选人身份。
独立评分者 1 / 2	按同一套锚点分别评分，每一项都写作答证据。	必须经作答者逐题同意；只看获准的已提交作答，不看 HR 原分或另一人的分。
作答者	决定是否分享给每一位评分者；另决定是否纳入本轮研究统计。	可查看自己的任务、授权和研究参与状态，可关闭访问。
技术测试人员	用合成数据测试存取、版本、撤回和计算。	测试记录必须标为合成；不能冒充真实专家或真人盲评。

数据怎样流动

冻结岗位与任务 → 专家独立意见 → 匿名作答 + 本人授权 → 固定两人盲评 → 逐维度一致性 / 总分一致性 → 统计快照 → 人工处理记录。

专家意见和盲评分数是两种不同证据。前者回答“任务是否相关、清楚、可观察”；后者回答“同一份作答，两人是否给出接近的分数”。两者都不等于最终招聘决定。

开始前，把本轮方案写完整

入口：在 HR 正式任务旁点击验收入口，或打开 validation.html。用参考任务编号建立一轮；参考任务必须属于自己发布职位的有效申请。版本来自该申请冻结的 job description，不会偷偷换成后来改过的岗位。

必须写下	写法与检查
任务范围	选定 resource-plan 或 record-audit、A 或 B；一次只研究同一题、同一变式。
统一条件	负责人须核对实际施测语言；系统不监考。语言、工具和建议分钟数一致；AI 可用与独立完成分开建轮次。
固定两名评分者	填写不同账号 UID；都不能是发布者或该份作答者。
专家名单与资历	填写指定账号 UID；相关岗位经验须负责人核对，写依据，不收证件号。
抽样计划	从哪些成人岗位群体招募、怎样选人、避免哪些偏差；校准样本与正式样本分开。
验收与分歧规则	先约定读哪些指标、怎样处理不确定区间和缺失值、何时改题并重新收集。
人数计划	页面默认 30 份作答、6 位专家，只是可调整的起点，不是通用合格线。

冻结前先备齐专家账号名单；冻结后不能补专家或更换评分者，名单有误需另开一轮。系统当前单轮上限 60 名不同参与者、10 个专家账号。需要更大研究时应先设计扩展方案；不要把多轮不同条件的数据直接拼接来凑人数。

冻结后不能改什么

题目、变式、语言、工具、时间、评分者和预先方案均保留原版本。发现问题，记录修订理由并新建下一轮。不要先看分数再降低原定要求。

负责人实际操作清单

顺序	操作	完成时应看见
1	用已验证账号登录，打开正式任务的验收入口。	页面显示自己的账号 UID；不能读取别人的轮次。
2	填标题、参考任务、两名评分者 UID、专家 UID 和研究方案。	保存后出现轮次编号，阶段为 draft。
3	核对全部版本后勾选冻结确认。	阶段变 collecting，生成每位专家的独立入口。
4	人工核对每名专家及评分者的岗位经验。	保留核对姓名、岗位、方法、日期；合成记录仍标合成。
5	让专家分别填写意见，不在提交前开“对答案”会议。	意见提交后只读；负责人能看，其他专家不能看。
6	加入同版本、同条件的已提交正式任务。	出现 C001 等匿名编号及两个独立授权入口。
7	让作答者处理两份阅卷授权，再处理研究统计同意。	只有授权有效的资料才进入新统计。
8	等待两人分别评分，再保存统计及处理记录。	Firebase 读回确认，快照包含来源摘要及排除原因。

资历记录不可覆盖。若记录写错，不把原合成核对改成真人核对；保留旧轮并新开一轮。系统保存的是负责人的核对声明，不替你认证专家身份。

专家审题表：怎么给 1 到 4 分

专家先看冻结岗位、题干、材料、标准答案及四个评分维度。每一维都评下面四项，并写能定位到原文的意见。不能只留“很好”“合理”。

审查项	1 分	2 分	3 分	4 分
相关性	与岗位无关	联系较弱，需大改	相关，有小改动	直接对应核心任务
清楚度	无法确定要做什么	多处歧义	基本清楚，需润色	材料与要求清楚
可观察性	无法由答案判断	证据不足，易猜	大体可由答案判断	锚点能指向具体证据
公平性	存在明显无关门槛	风险较大，需修改	有可处理的风险	目前未发现无关门槛

四项审查不能混成一个“有效率”

内容效度指标只使用“相关性”的 3 / 4 分，其他三项单独保留供修订。公平性 4 分仅表示该专家本次未发现问题，不是统计公平性证明。

每个维度的意见模板

问题在：题干第____段 / 材料第____项 / 锚点____。
可能导致：_____。
建议改成：_____。
需要补证据或向谁核实：_____。

另外填写：相关专业背景；利益冲突（无冲突填 none）；任务未覆盖的重要工作；建议修改、进入受控试测，或不适用。勾选独立审阅与是否合成测试。

专家要抓住的四类问题

1. 有没有测错东西

资源规划任务应观察计算、预算与时间约束、取舍及核验；不能把漂亮文案或熟悉某个产品当成能力。记录核验任务应观察去重、最新状态、异常跟进及推理；不能把打字快等同于细心。

2. 标准答案有没有容许合理路径

标准答案用于核算，不要求所有人说同一句话。不同但正确的推导可得到同级分；条件不足时应允许“目前不能确认”，并要求说明缺什么资料。不能为了跟标准数字一致而鼓励编造。

3. 哪些背景差异会干扰结果

检查语言难度、文化背景、对行业术语的熟悉程度、设备与辅助工具需求、阅读或操作障碍。记录合理调整；调整后的条件应单独建轮，不能直接和原条件混算。

4. 岗位覆盖是否足够

把岗位核心工作逐条列出来，写明“本题有观察”“本题没观察”“该岗位不适用”。任务只覆盖一小部分岗位要求时，不把该题总分叫做整个人的职业能力。

岗位工作 / 技能	题目证据位置	有 / 无 / 不适用	修改建议
_____	_____	_____	_____
_____	_____	_____	_____
_____	_____	_____	_____

审题后先记录分歧再讨论。讨论形成的修订要进入新版本；不能改写专家已独立提交的原始意见。

正式任务评分表：资源规划

题型 resource-plan；A / B 是不同材料。评分使用本轮冻结的题目与原始锚点，以下是中文操作摘要，在线标准为准。

维度	1 分	2 分	3 分
资源与产出计算	合计或最优值有误，缺少可复核算式。	合计正确，独立找出最优可行方案。	正确，并穷举组合或给出充分最优性证明。
约束与行动	漏看预算、时间或保障条件。	满足全部约束，写清选项与下一步。	还说明剩余资源及突发变化的应对。
取舍与推理	只有结论，未对应约束。	比较可行替代方案，说明选择与放弃。	指出假设、边界及条件改变后的调整。
验证与不确定性	没有可执行的复核步骤。	有独立核对步骤和待确认项。	核对可重现，指明证据、负责人和纠错。

评分者填写区

匿名作答编号	评分者本人 UID	题目 / 变式 / 条件	阅读及提交日期
_____	_____	_____	_____

维度	分数 1 / 2 / 3 / 未观察	引用作答与判断理由
计算	_____	_____
约束	_____	_____
推理	_____	_____
核验	_____	_____

未观察填空值，不填 0。不能仅因用了不同解法而扣分；也不能只看系统数值检查就省去人工观察。

正式任务评分表：记录核验

题型 record-audit。事件行数、不重复运单数、最新状态与冲突状态是不同概念；B 版含冲突，不能拿 A 版完成数直接套用。

维度	1 分	2 分	3 分
去重与统计	把事件行当运单数，或完成数不对。	正确去重，按最新状态核对运单与完成数。	计算可重现，保留重复与冲突处理记录。
异常与跟进	漏掉异常，或把冲突当完成。	列全未完成 / 冲突运单，给出核实步骤。	按影响排序，明确证据与责任人。
取舍与推理	只有结论，未对应条件。	说明可行做法与取舍理由。	检查假设及边界，解释条件改变的处理。
验证与不确定性	没有可执行复核。	有独立复核并指出待确认项。	过程可复现，说明证据、责任人与纠错。

两套题怎样分开验收

两类任务各有 A / B，共四个题目版本。每个版本、语言和工具条件分别建轮次；当前统计不是等值研究，不证明 A 和 B 难度相同。岗位相关性也需按目标岗位分别检查。

缺少证据时怎么写

“这份回答没有说明最新时间相同但状态冲突的处理，因此该观察项暂缺；需向作答者提出澄清，而不是自动记零或推断撒谎。”

追加澄清或评分更正走已有工作样本复核流程，保留原版本。本轮统计固定使用原始独立盲评；事后讨论后的分数不能悄悄替代它，否则会夸大独立一致性。

独立盲评：先分别评分，再讨论

阶段	执行要求	不能这样做
准备	选同一题目、同一条件；去掉姓名、联系方式等识别信息。	不改写答案的实际内容来“美化”。
校准	可用另外的练习样本讲锚点，记录讨论。	校准样本不计入正式一致性样本。
正式评分	两人分别登录；只引用作答证据；提交前不讨论。	不看 HR 原分、另一位分数或候选人的 CV。
独立声明	声明本人评分、未讨论、是否用 AI、是否认出身份、冲突。	自动脚本或 AI 评分不能勾成独立真人评分。
提交	分数、证据、声明一起保存，原记录不可覆盖。	不给“为了接近另一位评分”而修改的入口。
复核	负责人看逐项分歧，记录规则歧义和改进。	不能先取平均再说两人一致。

匿名是受限盲评，不是绝对匿名保证。答案正文可能透露身份；认出本人或存在冲突要如实声明，该记录从真人验收统计排除。负责人的去标识核对也必须完成。

正式评分前自查

☐ 我没看到另一位和 HR 的原分。
☐ 我没有与他人讨论这份答案。
☐ 我按实际情况申报 AI 和工具使用。
☐ 我给每一项分数都留下可追溯的证据。
☐ 我知道提交后保留原记录。

三份同意与撤回的区别

作答者看到的是三个独立决定，不由 HR 代勾选。只同意提交给 HR，不代表已同意交给两名研究评分者。

同意	开启什么	关闭后
给评分者 1 的单题分享	让指定评分者读这一题已提交的作答。	该评分者站内读取关闭，新统计排除本例。
给评分者 2 的单题分享	让另一名指定评分者读同一题作答。	同上；不能靠一位评分者补齐两人一致性。
纳入本轮研究统计	确认作答是否由本人完成、是否合成测试，并许可统计使用。	不再计入随后重新计算的统计；两名评分者的阅卷分享需另行关闭。

保留什么、不会承诺什么

系统保留不可覆盖的旧统计快照和审计记录，并把来源变化标记出来。撤回后不会把旧数字继续显示成当前结果，也不承诺抹除别人此前已经看见的内容。此功能是关闭站内访问与后续统计纳入，并非全量删除请求工具。

“合成资料”与“真人完成”不是同一个问题：真人可根据虚构案例亲自作答，但必须如实声明。自动脚本填写的案例只能作为软件演示；专家与评分者的资历和独立性还要另核对。

撤回后测试

刷新负责人页面：该案例列出排除原因；新统计人数减少。旧快照仍在，并标记来源已变化。评分者直接读取应被拒绝。作答者仍能读自己的研究同意记录。

一致性数字到底怎么算

指标	回答的问题	本系统计算方式
同分比例	两人给完全相同分的比例？	同分的成对案例数 ÷ 可比较的案例数。
平均绝对分差 MAD	通常相差多少分？	所有 |评分 1 − 评分 2| 的平均值。
有向分差	某位是否持续打得较高？	平均（评分 2 − 评分 1）。保留正负号。
线性加权 Kappa	考虑随机一致后，逐维度的一致性如何？	等级固定为 1、2、3；不一致权重 |a − b|/2；κ=1 − 观察不一致/边际期望不一致。
ICC(A,1)	完整总分的绝对一致性如何？	双向、绝对一致、单次评分；本轮固定选定的两位评分者。

读一个简单例子

某维度六份作答分别为 (1,1)、(1,2)、(2,2)、(2,3)、(3,3)、(3,1)：同分 3/6=50%，MAD=4/6≈0.667，线性加权 Kappa=0.25。0.25 不是 25% 录用概率，也不是专业效度 25%。

不要凑样本

四个维度分别统计；四项分数不当作四个人。只有两位对四个维度都给了分，才计算该案例总分的 ICC。缺项不补零；每项报告实际人数和缺失数。同一参与者不能重复计入本轮。

同分比例高，也可能因为人人都给同一个分；此时 Kappa 可能无定义。负系数保留，提示进一步检查；图表不会把负值截成零。

内容证据、区间与不足怎么读

专家相关性：I-CVI 与 S-CVI

某评分维度有 m 位有效专家，给相关性 3 或 4 的有 r 位：I-CVI=r/m。S-CVI/Ave 是四个维度 I-CVI 的平均；S-CVI/UA 是被所有专家评为相关的维度比例。缺少必要评价时总体指标留空，并显示缺失。

这些是专家相关性意见的整理方式，不是“整套测评的效度百分比”。清楚度、可观察性、公平性保留原分和意见，不混进上述公式。专家互相认识、背景相近等局限应另写。

95% 区间：按参与者抽样，不按维度抽样

对完整成对案例做 2,000 次有放回重抽样，分别重算指标，取 2.5% 和 97.5% 分位点。每个维度和总分各用确定的随机种子，便于复算；不是另找两名真人再评 2,000 次。

情况	系统显示	验收人要做
少于 10 份可比较作答	不显示自助区间，说明原因。	继续收样本，不能读成 0 或通过。
大量重复分，区间无法估计	有效重抽样少于 80% 时留空。	检查评分范围、任务区分度与方法适用性。
少于 3 份完整总分	ICC 留空。	不伪造总体能力结论。
区间很宽或含负值	如实显示实际范围。	由统计人员解释，不能只挑好看的点估计。

10 份与 80% 是本软件的显示保护条件，不是公认的研究合格标准。百分位自助法在小样本、离散和退化数据下有局限，正式研究应由统计人员预先选择样本量、方法和精度要求。

技术实现和第二条核算路径

部分	技术 / 方法	可追溯位置
网页与表单	HTML、CSS、JavaScript；中文、英文、马来语。	validation.html / .css / .js
登录与存储	Firebase Auth 验证邮箱；Firestore；按调用者令牌读写。	api/validation.js；lib/validation-service.js
版本与竞态	四题内容指纹、不可覆盖记录、乐观并发、原子提交与幂等编号。	formal-work-store.js；validation-definitions.js
主统计实现	Kappa：固定 3×3 混淆矩阵；ICC：双向方差分析。	validation-statistics.js
独立数值核对	Python Fraction 重建列联表；ICC 用协方差恒等式。	tests/validation-stat-crosscheck.py
区间核对	NumPy 独立协方差、同一抽样索引、线性分位点。	tests/validation-stat-fixtures.mjs

ICC 独立核对用的式子

设两列样本方差为 V1、V2，样本协方差 C，均值差 d，样本数 n：ICC = 2C / [V1+V2+d² (V1+V2 2C)/n]。它与主程序的方差分析公式使用不同计算路径，但验证的是同一统计定义。

本次 160 组随机合成资料，各比 Kappa 和 ICC，共 320 项点估计；另独立复核 2,000 次 ICC 重抽样和区间端点。差异容许 1×10 ⁻¹ ；测试通过只说明这些数值与实现一致，不验证专家判断。

统计快照带 sourceDigest 和统计版本。负责人打开页面时从当前授权及原评分重算；存储统计不符会提示，不能据它创建人工处理记录。摘要是溯源校验，不是不可伪造的密码学签名。

测试人员怎样验收，不只点开页面

测试	具体做法	通过的证据
完整链路	负责人建轮、冻结；专家提交；候选人授权；两人评分；保存快照。	用各自账号从 Firebase 服务端读回原记录，值及版本一致。
账号隔离	专家读候选人 CV / 问卷 / 游戏，评分者读原 HR 分或另一人分。	读取被拒绝；页面不泄露这些内容。
记录不可覆盖	对提交后的意见、评分、快照直接更新。	被规则拒绝；历史原记录仍在。
旧页面及重复点击	保留旧版本，再从另一窗口修改；重试同一操作编号。	冲突明确；确认丢失后的重试不产生重复快照。
撤回	关闭研究同意，再关闭单题分享并刷新。	新统计排除，旧快照标过期，评分者读取被拒。
合成与真人	全部用合成账号及脚本数据跑一遍。	合成区有记录；真人区人数仍为 0，状态待验证。

本机自动检查记录

本轮 Node 测试 89 项通过；Firestore 规则检查 566 项通过（新增 126 项，旧回归 440 项）。包括最大 10 人专家面板的原子冻结。实际线上与手机、三语记录另见 release.json，不能用本机检查替代。

复现：先安装仓库与 firebase/tests 的现有依赖，在本机 8180 启动 Firestore Emulator，再执行 firebase/tests/run-all.mjs；运行 node --test tests/*.test.mjs；独立统计核对运行 tests/validation-stat-crosscheck.py。测试必须使用 demo 项目，不能把权限种子写进正式项目。

交给真人的验收签字表

此页留给真实验收人员。空白表示尚未完成，不能由自动测试脚本代签。没有收集到的真实资料请保持空白并填写阻碍。

检查项	负责人 / 日期	证据编号 / 结论
预先方案经岗位专家与统计人员核对	_____	_____
专家相关岗位背景经人工核对	_____	_____
专家独立意见已收齐；分歧已记录	_____	_____
目标人群、样本与排除标准符合计划	_____	_____
两评分者独立性声明及盲评条件成立	_____	_____
缺失、负值、区间及不确定性已解释	_____	_____
公平性风险、合理调整与限制已记录	_____	_____
原材料 / 原分 / 快照 / 处理记录可追溯	_____	_____

允许写的处理结论

继续收集证据；修改材料并开新轮次；仅在受控条件试测。当前软件不提供“整体效度通过”按钮。正式研究或部署决策由有资格的人员根据明确范围、证据和用途作出，另附报告。

本轮仍待：真实专家审题、真实独立人工一致性、A/B 等值、岗位预测效度、适用人群与公平性研究。不能因达到页面计划人数就把这些全部划为完成。

入口、故障处理与参考依据

在线工作台：aligna-two.vercel.app/validation.html
PDF 直接下载：aligna-two.vercel.app/validation-guide.pdf
代码与最新验收记录：github.com/EvaCeryana/aligna（需仓库权限）

看到的问题	先检查什么
专家入口打不开	是否登录被分配的已验证账号；轮次是否冻结；专家访问是否撤销。
分数未进入真人统计	看逐例排除原因：两份授权、研究同意、版本、资历、独立声明和合成标记。
旧快照不能记录处理结论	授权或材料可能变化；先刷新并保存新快照，保留旧记录。
保存失败或版本冲突	输入保留，重新读取再核对；不要自行改数据库绕开规则。
没有合适的材料 / 岗位	不伪造岗位证据；按原流程补充岗位相关性后新建轮次。

方法来源与适用范围

以下为方法依据，查阅日期 2026-10-23；不是任何组织对 Future Fit 的认证。

SIOP（2023）：AI 招聘测评的验证与使用建议
岗位相关性、可靠性与公平性需按用途提供证据。

Koo & Li（2016）：ICC 选择与报告指南
选择模型、绝对一致 / 一致趋势、单次 / 平均评分，并报告区间。

R irr 官方文档：kappa2 与 icc
加权一致性定义；ICC 另见同站 icc.html。

Kassam-Adams 等（2015）：内容效度的迭代评审方法
本项目借鉴 I-CVI、S-CVI 汇总；原研究场景不同，不能直接转移其效度结论。